FINAL PROJECT – DATA SCIENCE

DARI VOLUME KE KESIAPAN

Segmentasi Wilayah dan Prioritisasi Leads UMKM

Klay (Skalar Solutions) – POS + AI Sales Analytics

Studi kasus: 30 kabupaten/kota Provinsi Jawa Tengah

Data: 2023–2024 | 90 segmen sektor × wilayah

Kelompok 13

Ayu Safitri (2610501106)

Carissa Zia W. F (2610514008)

Gerard Harjuno N (2610512189)

Fakultas Ilmu Komputer

Universitas Pembangunan Nasional "Veteran" Jakarta

1. Ringkasan Eksekutif

Klay menjual POS dan AI Sales Analytics kepada UMKM. Pertanyaan investasi utamanya bukan “wilayah mana yang paling banyak usahanya?”, tetapi “segmen mana yang paling siap membeli, mengadopsi, dan bertahan?” Laporan ini menjawab pertanyaan tersebut dengan menyegmentasikan 30 kabupaten/kota di Jawa Tengah dan memberi skor pada 90 segmen sektor × wilayah.

Temuan utama

- **Top 5 segmen berada di Kota Semarang dan Kota Surakarta.** Kombinasi volume besar, kepadatan tinggi, IPM tinggi, dan adopsi keuangan digital membuat keduanya paling siap untuk pilot berbayar.
- **Volume bukan prioritas.** Baseline yang hanya mengurutkan jumlah unit menghasilkan Top 5 yang seluruhnya kabupaten dan seluruhnya Ritel; tidak ada satu pun yang beririsan dengan Top 5 ICP (overlap 0/5; Spearman ρ = 0,738).
- **Tiga tipe wilayah.** Hub Digital Matang (3 wilayah), Sentra Perdagangan Padat (14), dan Wilayah Rintisan (13). Masing-masing membutuhkan motion dan paket SDR yang berbeda.
- **Ritel mendominasi populasi.** Dari 1.021.062 unit target, 68,9% adalah Ritel, 22,4% F&B, dan 8,8% Jasa. Namun prioritas tetap ditentukan oleh kesiapan, bukan hanya ukuran.

Rekomendasi inti

- Jalankan pilot berbayar di Ritel dan F&B Kota Semarang serta Kota Surakarta.
- Pakai Sentra Perdagangan Padat sebagai mesin volume dengan POS basic dan onboarding.
- Perlakukan Wilayah Rintisan sebagai pipeline edukasi, bukan target volume jangka pendek.

2. Latar, Tujuan, dan Ruang Lingkup

Sebagai produk B2B SaaS, Klay perlu memilih wilayah dan segmen yang memberi rasio konversi terbaik terhadap biaya akuisisi. Tugas 2 sudah membangun kerangka ICP dan filter kualitas data, tetapi berhenti pada rancangan bobot. Final Project ini menutup tiga celah: (1) segmentasi wilayah dengan K-Means, (2) skor prioritas pada level sektor × wilayah, dan (3) uji ketahanan skor terhadap perubahan bobot.

Ruang lingkup: 30 kabupaten/kota yang lolos filter kualitas, tiga sektor target (Ritel, F&B, Jasa), data cross-section 2023–2024, dan horizon rekomendasi satu sampai dua kuartal. Analisis tidak mengklaim kausalitas; hasil adalah prioritisasi berbasis data publik.

2.1 Pertanyaan analisis

1. Bagaimana mengelompokkan wilayah berdasarkan ukuran pasar, kepadatan sektor, kesiapan digital, adopsi digital, dan aktivitas ekonomi?
2. Segmen sektor × wilayah mana yang paling diprioritaskan untuk sourcing leads?
3. Seberapa berbeda prioritas ICP dibanding baseline volume?
4. Seberapa sensitif Top 5 terhadap perubahan bobot?
5. Sumber leads mana yang layak secara hukum dan etika untuk dipakai?

3. Data dan Metodologi

3.1 Sumber data

Empat sumber publik dipakai. Tiga sumber pertama membangun konteks wilayah; sumber keempat memberi dimensi sektor yang tidak tersedia di Tugas 2.

Sumber	Level & isi	Peran dalam analisis
BPS Jateng, Provinsi Jawa Tengah Dalam Angka 2025	Kab/kota; PDRB per kapita 2024, simpanan/tabungan, sarana perdagangan	Aktivitas ekonomi, adopsi digital, konteks retail
BPS Jateng, Penduduk 2024	Kab/kota; jumlah penduduk dan kepadatan	Denominator kepadatan sektor
BPS Jateng, IPM 2024	Kab/kota; IPM dan pengeluaran per kapita	Kesiapan digital dan daya beli
Dinkop Jateng, Pelaku Usaha per Lapangan Usaha 2024	Kab/kota × 17 KBLI; 595 baris	Jumlah unit Ritel, F&B, dan Jasa aktual

Sumber sektor: https://data.jatengprov.go.id/dataset/f23725ac-b792-4e7d-9506-0d16f392f6a4/resource/4e820490-c1fc-4b8e-b398-d9ff49caad45/download/jumlah-pelaku-usaha-berdasarkan-lapangan-usaha-hasil-pendataan-lengkap-koperasi-usaha-mikro-kec.xlsx

Tiga kategori KBLI dipetakan ke sektor Klay: perdagangan besar/eceran menjadi Ritel; akomodasi dan makan/minum menjadi F&B; aktivitas jasa lainnya menjadi Jasa. Dataset ini mencakup pelaku usaha hasil pendataan Dinkop, bukan seluruh UMKM, sehingga tetap dibaca sebagai proxy populasi.

3.2 Pembersihan dan pembentukan segmen

- 35 wilayah dibaca dari dataset sektor; kode wilayah diparse dari format desimal (33.10 → 3310) agar Klaten dan Jepara tidak hilang.
- Data sektor di-pivot menjadi tiga kolom sektor dan digabung ke master 30 wilayah yang lolos filter Tugas 2.
- Unit sektor dijumlahkan menjadi total target; kepadatan dihitung per 100.000 penduduk.
- Setiap wilayah × sektor menjadi satu segmen: 30 × 3 = 90 baris.

Total unit target: Ritel 703.132 (68,9%), F&B 228.270 (22,4%), dan Jasa 89.660 (8,8%). Ritel adalah pasar terbesar, tetapi F&B dan Jasa tetap dianalisis karena kepadatan dan kesiapan digitalnya berbeda.

3.3 Komponen dan bobot ICP

Lima komponen dinormalisasi Min-Max. Bobot dipilih dari rancangan Tugas 2 dan tidak diubah setelah melihat hasil: Ukuran Pasar 25%, Kepadatan Sektor 25%, Kesiapan Digital 20%, Adopsi Digital 15%, dan Aktivitas Ekonomi 15%.

Komponen	Indikator	Bobot
Ukuran Pasar	Total unit Ritel + F&B + Jasa	25%
Kepadatan Sektor	Unit target per 100.000 penduduk	25%
Kesiapan Digital	Rata-rata MinMax IPM dan pengeluaran per kapita	20%
Adopsi Digital	Rata-rata MinMax simpanan dan tabungan per kapita	15%
Aktivitas Ekonomi	PDRB per kapita 2024	15%

3.4 K-Means dan skor segmen

K-Means dijalankan pada lima komponen wilayah dengan k = 2–6 untuk evaluasi, tetapi pemilihan dibatasi pada k = 3–5 sesuai ketentuan. k = 3 dipilih karena silhouette tertinggi di dalam rentang (0,390); k = 2 memang lebih tinggi (0,578) tetapi di luar rentang. Skor segmen menggabungkan komponen wilayah dengan volume dan kepadatan sektor yang dinormalisasi pada 90 segmen.

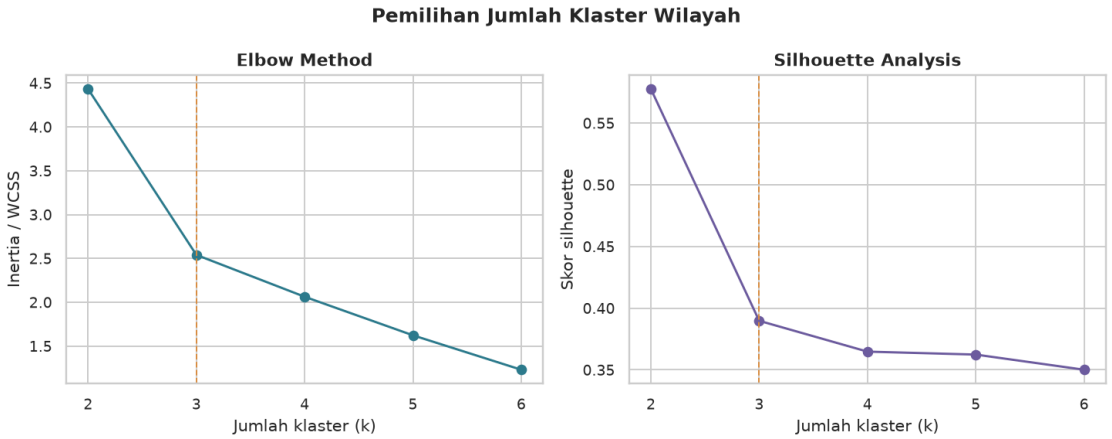
Baseline hanya mengurutkan 90 segmen berdasarkan jumlah unit sektor. Perbandingan memakai overlap Top 5 dan Spearman ρ. Sensitivitas menggeser bobot digital, adopsi, dan PDRB sebesar ±5–10 poin persentase, lalu menghitung ulang peringkat.

4. Hasil

4.1 Evaluasi klaster

k	Inertia	Silhouette	Catatan
2	4,432	0,578	Di luar rentang wajib
3	2,540	0,390	Dipilih: tertinggi dalam rentang 3–5
4	2,062	0,365	Alternatif
5	1,623	0,362	Alternatif
6	1,230	0,350	Di luar rentang

Tiga klaster cukup untuk memisahkan wilayah berdasarkan kesiapan digital dan ukuran pasar. Silhouette 0,390 menunjukkan struktur yang moderat, bukan pemisahan sempurna; karena itu label klaster dibaca sebagai tipe strategi, bukan taksonomi kaku.



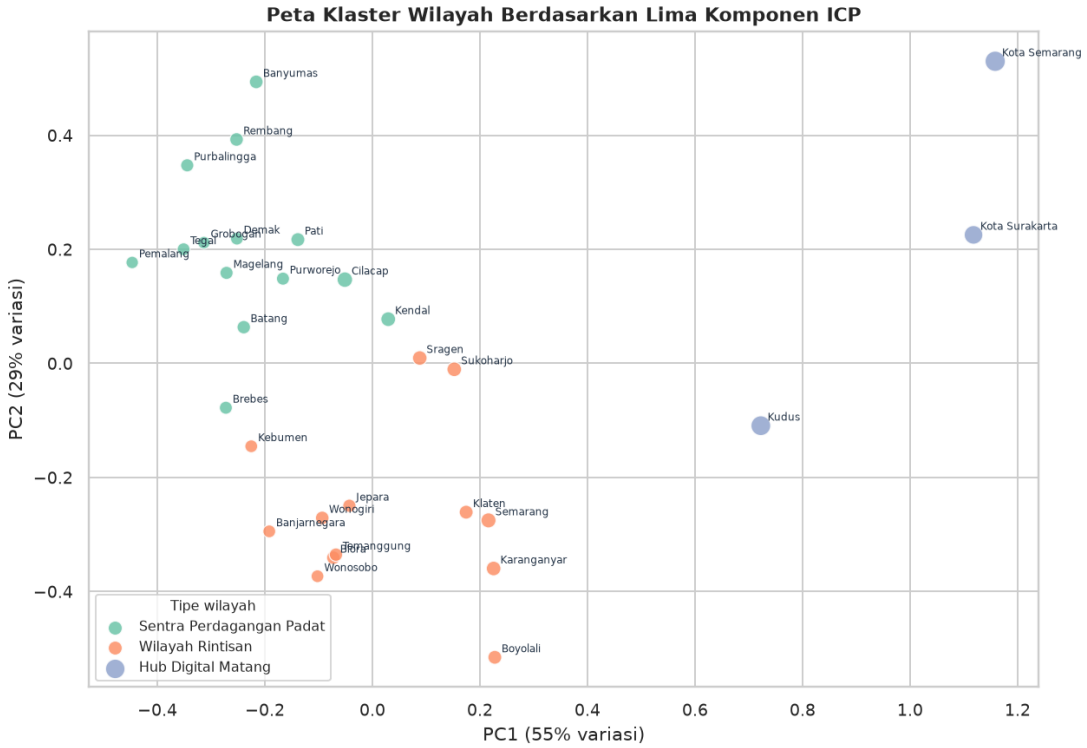
Gambar 1. Elbow dan silhouette untuk pemilihan k. Garis putus-putus menandai k = 3.

4.2 Profil klaster

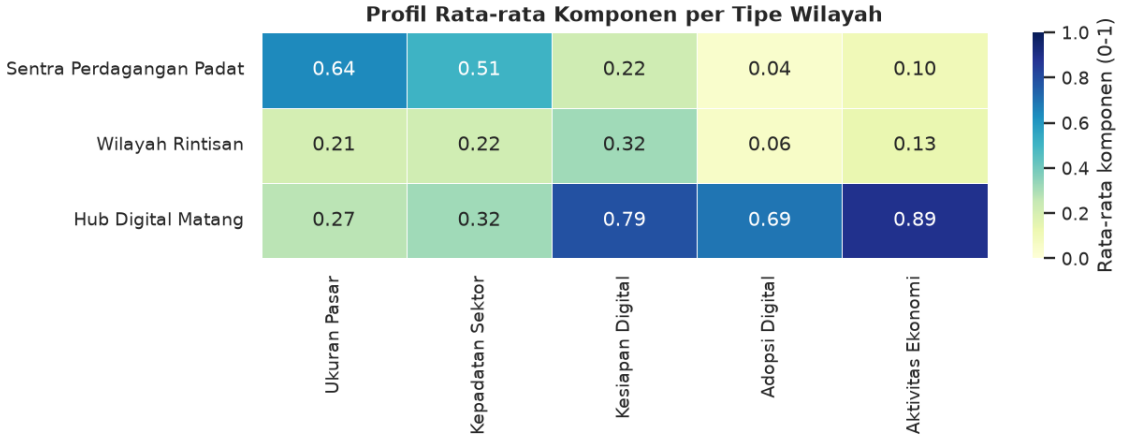
Tipe wilayah	Jumlah	Ukuran	Kepadatan	Digital	Adopsi	Ekonomi
Hub Digital Matang	3	0,271	0,318	0,789	0,694	0,888
Sentra Perdagangan Padat	14	0,641	0,512	0,223	0,040	0,103
Wilayah Rintisan	13	0,209	0,222	0,318	0,058	0,134

Hub Digital Matang hanya berisi tiga wilayah (Kota Semarang, Kota Surakarta, Kudus), tetapi unggul jauh pada kesiapan digital, adopsi, dan aktivitas ekonomi. Sentra Perdagangan Padat adalah kutub volume: 14 kabupaten dengan ukuran dan kepadatan tinggi, tetapi adopsi digital

sangat rendah. Wilayah Rintisan adalah pasar edukasi dengan volume dan digital di bawah kedua klaster lain.



Gambar 2. Peta klaster wilayah pada dua komponen utama (PCA). Ukuran titik mengikuti aktivitas ekonomi.



Gambar 3. Profil rata-rata lima komponen per tipe wilayah.

4.3 Top 5 segmen

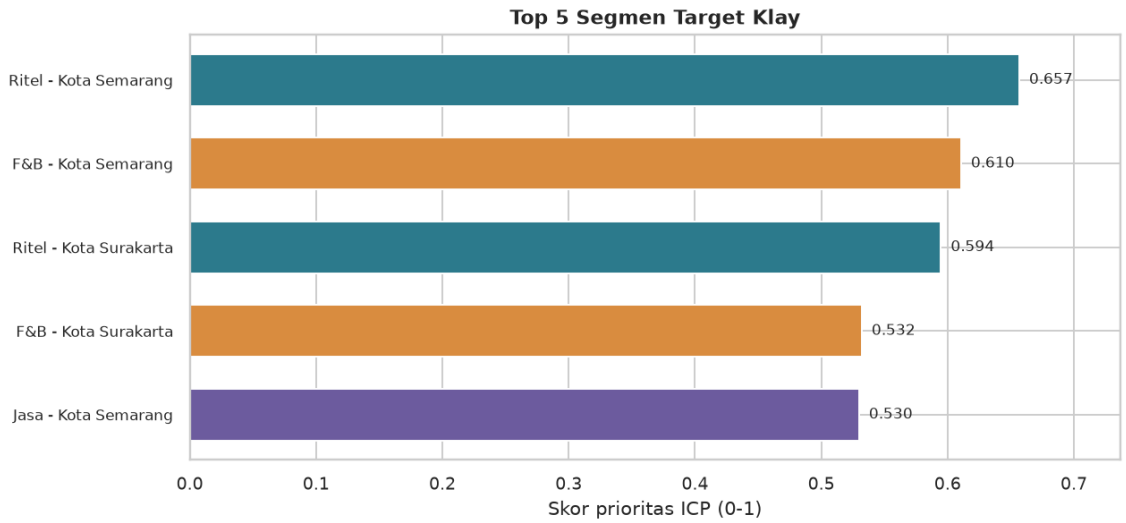
#	Sektor	Wilayah	Skor	Unit	Kepadatan	Tipe wilayah
1	Ritel	Kota Semarang	0,657	20.547	1.202	Hub Digital Matang
2	F&B	Kota Semarang	0,610	15.600	913	Hub Digital Matang
3	Ritel	Kota Surakarta	0,594	9.871	1.870	Hub Digital Matang
4	F&B	Kota Surakarta	0,532	6.269	1.187	Hub Digital Matang
5	Jasa	Kota Semarang	0,530	6.925	405	Hub Digital Matang

Top 5 seluruhnya berada di Hub Digital Matang. Ritel Kota Semarang memimpin dengan skor 0,657 dan 20.547 unit; F&B Kota Semarang mengikuti dengan 15.600 unit. Kota Surakarta masuk lewat Ritel dan F&B karena kepadatan sektornya lebih tinggi per penduduk, meskipun

volume absolutnya lebih kecil. Jasa Kota Semarang melengkapi Top 5 dengan 6.925 unit.

Implikasi komersial

- Kota Semarang adalah pasar akuisisi utama: volume besar, kepadatan tinggi, dan daya beli tertinggi.
- Kota Surakarta adalah pasar kepadatan: cocok untuk motion berbasis komunitas dan merchant padat.
- Konsentrasi Top 5 di tiga wilayah menandakan risiko konsentrasi; Banyumas, Purbalingga, dan Rembang adalah kandidat gelombang berikutnya.

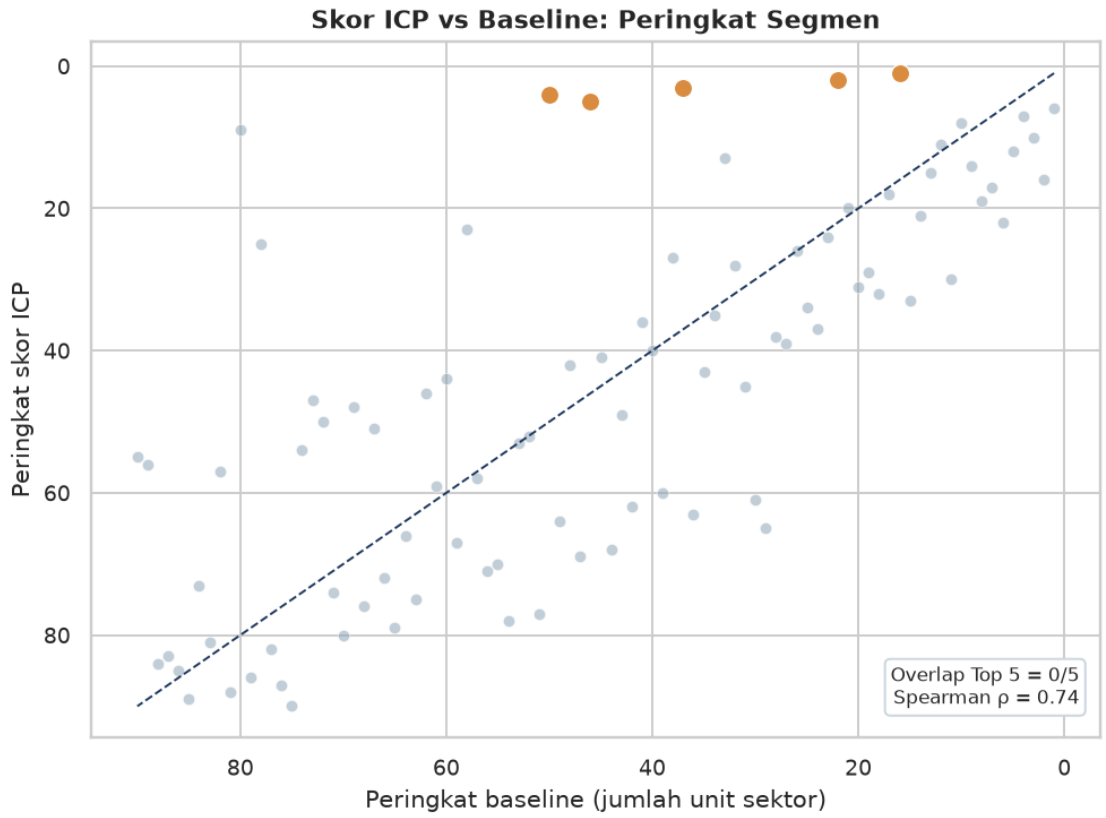


Gambar 4. Lima segmen prioritas utama berdasarkan skor ICP.

4.4 Baseline volume vs skor ICP

#	Top 5 ICP	Skor	Top 5 volume	Unit
1	Ritel Kota Semarang	0,657	Ritel Banyumas	44.960
2	F&B Kota Semarang	0,610	Ritel Tegal	39.767
3	Ritel Kota Surakarta	0,594	Ritel Grobogan	39.264
4	F&B Kota Surakarta	0,532	Ritel Purbalingga	37.960
5	Jasa Kota Semarang	0,530	Ritel Cilacap	35.905

Baseline didominasi Ritel di kabupaten: Banyumas (44.960), Tegal (39.767), Grobogan (39.264), Purbalingga (37.960), dan Cilacap (35.905). Tidak ada satu pun segmen yang sama dengan Top 5 ICP. Korelasi peringkat keduanya 0,738: arahnya positif, tetapi ujung distribusi berbeda karena baseline mengabaikan kesiapan digital dan kepadatan.

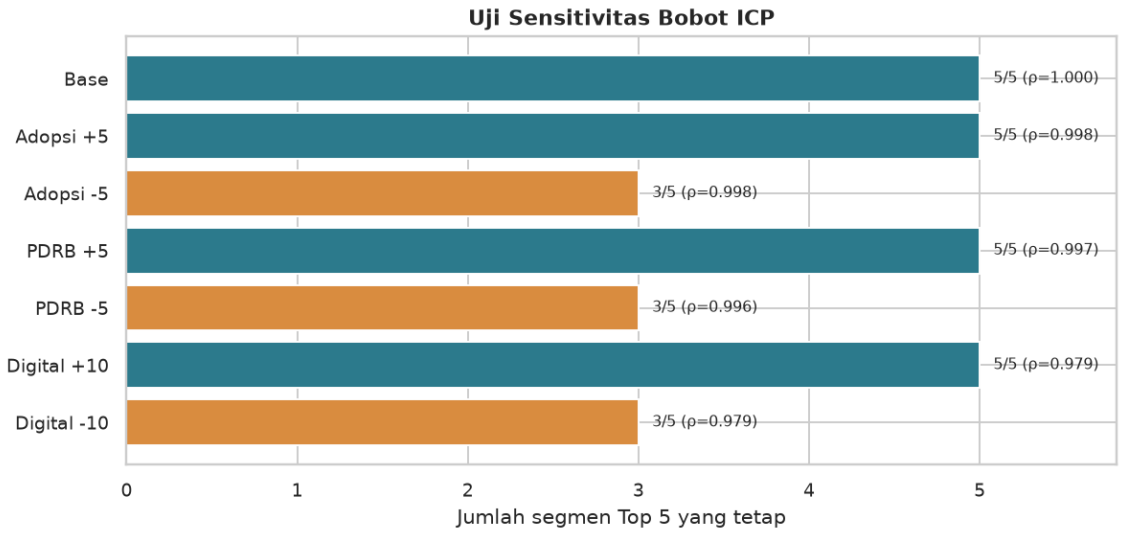


Gambar 5. Peringkat ICP vs baseline volume. Titik oranye adalah Top 5 ICP; overlap 0/5.

4.5 Sensitivitas bobot

Skenario	Overlap Top 5	Spearman vs base	Segmen berubah
Base	5/5	1,000	0
Adopsi +5	5/5	0,998	52
Adopsi -5	3/5	0,998	54
PDRB +5	5/5	0,997	50
PDRB -5	3/5	0,996	59
Digital +10	5/5	0,979	72
Digital -10	3/5	0,979	76

Spearman ρ tetap di atas 0,97 pada semua skenario, tetapi overlap Top 5 turun dari 5/5 ke 3/5 saat bobot adopsi, PDRB, atau digital diturunkan. Artinya urutan besar cukup stabil, namun segmen batas (terutama F&B dan Jasa) sensitif terhadap asumsi bobot. Untuk keputusan kuartalan, tiga nama teratas relatif aman; posisi keempat dan kelima perlu divalidasi dengan data pipeline.



Gambar 6. Uji sensitivitas bobot: jumlah segmen Top 5 yang tetap dan korelasi peringkat.

5. Pembahasan dan Strategi Go-to-Market

Hasil menunjukkan bahwa pasar terbesar bukan otomatis pasar terbaik. Kabupaten dengan puluhan ribu unit Ritel memiliki volume, tetapi kesiapan digital dan daya beli lebih rendah. Klay menjual alat analitik yang membutuhkan data transaksi dan disiplin operasional; karena itu wilayah dengan IPM, adopsi simpanan, dan PDRB tinggi lebih mungkin mencapai time-to-value yang cepat.

5.1 Tiga motion SDR

Tier	Target	Profil	Penawaran	Channel
A	Top 5: Ritel/F&B/Jasa Kota Semarang & Surakarta	Adopsi digital tinggi; volume dan kepadatan tinggi	Demo AI Sales Analytics; pilot 30 hari; integrasi POS	Direct sales; komunitas merchant; referral
B	Ritel di 14 Sentra Perdagangan Padat	Volume besar; adopsi rendah	POS basic + onboarding; literasi digital	Dinas/koperasi; komunitas pasar; agen lokal
C	Ritel/F&B di 13 Wilayah Rintisan	Volume dan digital rendah	Produk ringan; uji coba; edukasi	Event UMKM; mitra lokal; konten

Tier A memakai sales-assisted motion karena nilai kontrak dan kompleksitas integrasi lebih tinggi. Tier B memakai channel partner dan komunitas untuk menekan CAC. Tier C memakai edukasi dan produk ringan; targetnya bukan revenue jangka pendek, melainkan pipeline dan brand presence.

5.2 Target dan urutan eksekusi

1. Kuartal 1: pilot 10–15 merchant Ritel/F&B di Kota Semarang; ukur activation, GMV per merchant, dan retensi 30 hari.
2. Kuartal 1–2: replikasi pilot di Kota Surakarta dengan motion komunitas merchant padat.
3. Kuartal 2: uji paket POS basic di 3–5 kabupaten Sentra Perdagangan Padat (Banyumas, Purbalingga, Rembang).
4. Kuartal 3: bangun pipeline edukasi di Wilayah Rintisan; jangan paksakan target volume.
5. Setiap kuartal: hitung ulang skor dengan data sektor dan adopsi terbaru; validasi posisi 4–5.

Metrik yang harus dipantau

- Conversion rate dari qualified lead ke pilot.
- Activation: merchant menyelesaikan onboarding dan transaksi pertama di POS.
- Retensi 30/90 hari dan fitur AI yang benar-benar dipakai.
- CAC payback per tier dan waktu ke nilai (time-to-value).

6. Legalitas dan Etika Sumber Leads

Sebelum melakukan scraping, kami memeriksa robots.txt dan ketentuan layanan calon sumber. Prinsipnya: hormati robots.txt, jangan melanggar ToS, jangan mengambil data pribadi tanpa dasar yang sah, dan gunakan API atau data partner bila tersedia. Pemeriksaan dilakukan pada 2 November 2026; kebijakan dapat berubah.

Sumber	robots.txt	ToS	Status	Rekomendasi
Google Maps / Places	Dibatasi	ToS melarang	Dibatasi	Gunakan Places API berbayar; jangan scrape halaman maps
OpenStreetMap	Dibatasi	ToS mengizinkan dengan syarat	Diizinkan	Gunakan planet.osm atau ekstrak regional
LinkedIn	Dibatasi	ToS melarang	Dilarang	Jangan crawl; gunakan API/partner resmi jika perlu
Tokopedia	Dibatasi	ToS melarang	Dilarang	Jangan crawl; gunakan data mitra/API resmi
Shopee	Dibatasi	ToS melarang	Dilarang	Jangan crawl; gunakan Shopee API/afiliasi resmi
Portal Satu Data Dinkop Jateng	Diizinkan	ToS tidak jelas	Diizinkan	Gunakan unduhan resmi/API; batasi laju permintaan

Google Maps, LinkedIn, Tokopedia, dan Shopee tidak layak di-scrape: ToS melarang, dan untuk Google Maps jalur yang sah adalah Places API berbayar. OpenStreetMap menyediakan bulk data planet.osm dengan lisensi ODbL; gunakan ekstrak resmi, bukan crawling situs. Portal Satu Data Dinkop mengizinkan akses robots.txt, tetapi tidak memberi izin scraping eksplisit; gunakan unduhan resmi dan batasi laju permintaan.

Rekomendasi akuisisi data

- Untuk direktori merchant: gunakan Places API, data partner, atau opt-in merchant; jangan scrape.
- Untuk data publik sektor: gunakan portal Satu Data dan cantumkan atribusi.
- Untuk data sosial/profesional: jangan crawl; gunakan API resmi atau kemitraan.
- Simpan log sumber, tanggal akses, dan dasar penggunaan untuk audit internal.

7. Limitasi

- **Cross-section.** Data 2023–2024 tidak menangkap perubahan musiman atau dampak kebijakan; hasil adalah potret, bukan ramalan.
- **Proxy digital.** IPM, pengeluaran, simpanan, dan tabungan bukan ukuran langsung literasi digital atau penggunaan POS.

- **Cakupan sektor.** Dataset Dinkop mencakup pelaku usaha hasil pendataan, bukan seluruh UMKM; unit Ritel/F&B/Jasa adalah proxy populasi.
- **Kepadatan.** Denominator memakai penduduk, bukan jumlah usaha aktif; wilayah dengan banyak usaha kecil per penduduk bisa terlihat lebih padat.
- **K-Means.** Silhouette moderat (0,390); label klaster adalah alat strategi, bukan kebenaran absolut.
- **Bobot.** Bobot dipilih sebelum melihat hasil, tetapi tetap mengandung judgment; sensitivitas menunjukkan posisi 4–5 rentan.
- **Scraping.** Tidak ada scraping yang dijalankan; tabel legalitas adalah kajian dokumen, bukan nasihat hukum.

8. Kesimpulan

Prioritas Klay di Jawa Tengah adalah segmen yang siap mengadopsi, bukan sekadar yang besar. Ritel dan F&B Kota Semarang serta Kota Surakarta adalah kandidat pilot terkuat; Sentra Perdagangan Padat adalah mesin volume; Wilayah Rintisan adalah pipeline edukasi. Baseline volume menghasilkan Top 5 yang sama sekali berbeda, sehingga keputusan sourcing harus memakai skor ICP, bukan peringkat jumlah usaha.

Langkah berikutnya: validasi Top 5 dengan data pipeline internal, jalankan pilot 30 hari, ukur activation dan retensi, lalu kalibrasi bobot setiap kuartal. Sumber leads harus mengikuti jalur yang sah: API, data partner, atau opt-in merchant.

> **Satu kalimat untuk manajemen**
> “Jangan cari kota dengan usaha terbanyak; cari kota dan sektor dengan usaha yang paling siap membeli dan memakai Klay.”

9. Lampiran: Reproduksibilitas

Alur reproduksi dari akar proyek:

```
python3 scripts/build_final_dataset.py
python3 scripts/final_analysis.py
python3 scripts/make_final_notebook.py
jupyter nbconvert --to notebook --execute --inplace FinalProject_DS_Kelompok13.ipynb
python3 scripts/make_final_report.py
python3 scripts/make_final_slides.py
```

Berkas	Isi
FinalProject_DS_Kelompok13.ipynb	Notebook utama, sudah tereksekusi
data/processed/master_final.csv	30 wilayah, komponen, klaster, centroid
data/processed/segments_final.csv	90 segmen, skor, peringkat, baseline
data/processed/top5_segments.csv	Tabel Top 5 segmen
data/processed/scraping_legality.csv	Tabel legalitas sumber leads
data/processed/sdr_strategy.csv	Strategi SDR per tier
figures/final_*.png	Tujuh figur final
report/FinalProject_DS_Kelompok13.pdf	Laporan ini