Tugas 2 - Milestone 1 Final Project

Market Prioritization UMKM

Wilayah Target Sourcing Leads B2B SaaS

Skalar Solutions - Klay

POS + AI Sales Analytics untuk UMKM

Kelompok: 13

Anggota dan pembagian tugas

1. [Nama 1] - Data collection & data understanding
2. [Nama 2] - Data preparation & merging
3. [Nama 3] - EDA, visualisasi & rancangan bobot ICP

Studi kasus: 35 kabupaten/kota Provinsi Jawa Tengah

Periode data: 2023-2024 (time series UMKM 2019-2024)

Tanggal: 30 Oktober 2026

Dokumen ini merangkum proses data collection, data preparation, EDA, dan rancangan bobot ICP. Notebook pendukung dieksekusi tanpa error dan seluruh figur dihasilkan ulang dari notebook tersebut.

1. Ringkasan Eksekutif

Klay menjual POS + AI Sales Analytics ke UMKM. Untuk memprioritaskan wilayah sourcing leads, kami menyusun kerangka Indeks Calon Pelanggan (ICP) pada 35 kabupaten/kota Jawa Tengah. Data berasal dari empat sumber publik BPS dan Dinkop Jateng (2023-2024). Setelah pembersihan dan filter kualitas data, 30 wilayah lolos dan siap dianalisis.

- Kabupaten Banyumas, Cilacap, Kebumen, Purbalingga, dan Pemalang memimpin jumlah unit IMK, tetapi kepadatan IMK tidak otomatis sejalan dengan PDRB per kapita (korelasi -0,30).
- Kota Surakarta dan Kota Semarang unggul pada kepadatan pedagang pasar, IPM, PDRB, dan simpanan per kapita. Keduanya adalah segmen siap digital dengan daya beli tinggi.
- Kabupaten dengan IMK padat tetapi PDRB/IPM menengah (Kebumen, Wonosobo, Banjarnegara) adalah pasar volume besar dengan gap digitalisasi yang justru menjadi peluang Klay.
- Rancangan bobot ICP: Ukuran Pasar 25%, Kepadatan Sektor Target 25%, Kesiapan Digital 20%, Adopsi Pembayaran Digital 15%, Aktivitas Ekonomi 15%.

1.1 Ruang lingkup

Sesuai instruksi Tugas 2, pekerjaan berhenti pada perancangan bobot ICP. K-Means, skor indeks akhir, penentuan Top 5, dan uji sensitivitas bobot tidak dihitung di sini; bagian tersebut menjadi rencana milestone berikutnya.

Output utama: notebook Tugas2_DS_Kelompok13.ipynb yang tereksekusi, dataset mentah dan bersih di data/processed, sembilan figur EDA di figures, dan laporan ini.

2. Data Collection & Data Understanding

2.1 Sumber data

No	Sumber	Level	Kolom kunci	Keterbatasan
1	BPS Jateng, Provinsi Jawa Tengah Dalam Angka 2025	Kab/kota (35)	IMK 2023; PDRB 2024; sarana perdagangan 2024; simpanan/tabungan 2024	PDF; nama wilayah tidak membedakan kabupaten/kota; watermark dan sel en dash
2	BPS Jateng, Penduduk menurut Kabupaten/Kota 2024	Kab/kota (35)	kode wilayah, jumlah penduduk, kepadatan	Satu tahun; proyeksi penduduk
3	BPS Jateng, IPM menurut Kabupaten/Kota 2024	Kab/kota (35)	IPM, pengeluaran per kapita, indikator pendidikan/kesehatan	IPM agregat; bukan literasi digital langsung
4	Dinkop Jateng, Jumlah UMKM Binaan 2019-2024	Provinsi	tahun, jumlah UMKM binaan	Hanya UMKM binaan; 2024 baru s.d. TW II

Link akses: BPS Jateng - https://jateng.bps.go.id/id/publication/2025/02/28/6f9ad30e8755ed2b706cb979/provinsi-jawa-tengah-dalam-angka-2025.html ; Penduduk - https://data.jatengprov.go.id/dataset/79a-penduduk-laju-pertumbuhan-penduduk-distribusi-persentase-penduduk-kepadatan-penduduk-rasio-jenis ; IPM - https://data.jatengprov.go.id/dataset/6c4-indeks-pembangunan-manusia-ipm-menurut-kabupaten-kota ; UMKM - https://data.jatengprov.go.id/dataset/7e5-jumlah-umkm-binaan-jawa-tengah

2.2 Definisi operasional dan limitasi

IMK adalah Industri Mikro dan Kecil, yaitu unit usaha manufaktur berskala mikro/kecil. IMK dipakai sebagai proxy kepadatan sektor target, bukan total UMKM. Pedagang pasar adalah pedagang yang berjualan di pasar rakyat, proxy retail/F&B tradisional. Sarana perdagangan mencakup pasar, supermarket, dan pedagang pasar, bukan seluruh kanal retail modern. UMKM binaan adalah UMKM yang difasilitasi Dinkop Jateng, bukan populasi seluruh UMKM.

Keterbatasan utama: total UMKM per kabupaten/kota tidak tersedia seragam; QRIS merchant per kabupaten/kota tidak tersedia publik; data UMKM binaan hanya level provinsi; dan sebagian tabel BPS hanya tersedia dalam PDF sehingga memerlukan ekstraksi dan validasi manual.

3. Data Preparation

3.1 Pembersihan data

Tahapan pembersihan yang dilakukan:

- Ekstraksi tabel PDF dengan pdfplumber, lalu membersihkan angka dari watermark dan pemisah ribuan.
- Mengganti nama wilayah hasil ekstraksi dengan nama kanonik dari file penduduk berdasarkan urutan 35 wilayah dan kode wilayah (3301-3329 kabupaten, 3371-3376 kota).
- Mengisi sel en dash pada tabel sarana perdagangan dengan 0, karena tanda tersebut berarti tidak ada outlet, bukan data hilang.
- Memeriksa duplikat dan missing pada level kode dan nama wilayah; memastikan seluruh kolom numerik bertipe angka.

Hasil validasi: 35 baris, 35 wilayah unik, 0 duplikat, 0 missing. Tidak ada nilai negatif yang tidak wajar.

3.2 Merging lintas level

Data kabupaten/kota digabung dengan kode wilayah dan nama wilayah sebagai kunci. Data provinsi (time series UMKM binaan) tidak di-join secara aditif karena level agregasinya berbeda. Yang dilakukan adalah broadcast satu kolom konteks, yaitu pertumbuhan UMKM binaan 2023 (3,02%), ke seluruh kabupaten/kota. Kolom ini dipakai sebagai konteks, bukan tambahan kuantitas.

Mengapa tidak dijumlahkan: total UMKM binaan provinsi 2023 adalah 186.024, sedangkan total unit IMK 35 kabupaten/kota adalah 862.926. Keduanya mengukur populasi berbeda, sehingga penjumlahan akan menyesatkan. Perbedaan definisi ini dicatat sebagai limitasi.

3.3 Kriteria penggugur

Filter dipakai untuk membuang wilayah yang terlalu kecil atau ekstrem agar segmentasi tidak didominasi outlier. Kriteria: (1) data kunci kosong; (2) skala terlalu kecil, yaitu IMK < 10.000 unit; (3) outlier kepadatan, yaitu IMK per 100.000 penduduk > Q3 + 1,5 x IQR. Ambang 10.000 dipilih agar kota-kota kecil dengan basis manufaktur tipis keluar, tetapi wilayah dengan basis memadai tetap lolos.

Hasil: 5 wilayah gugur dan 30 wilayah lolos (di atas syarat minimal 20). Daftar wilayah gugur:

Wilayah	Tipe	IMK (unit)	IMK/100k	Alasan
Pekalongan	Kabupaten	60,456	5,933	IMK/100k > 5,298 (outlier)
Kota Magelang	Kota	3,025	2,471	IMK < 10.000 unit
Kota Salatiga	Kota	6,301	3,130	IMK < 10.000 unit
Kota Pekalongan	Kota	9,988	3,111	IMK < 10.000 unit
Kota Tegal	Kota	2,947	1,031	IMK < 10.000 unit

Filter ini secara tidak proporsional mengeluarkan kota-kota kecil. Dari enam kota, hanya Kota Semarang dan Kota Surakarta yang lolos. Ini adalah trade-off yang disadari: fokus pada wilayah dengan basis sektor cukup besar, sementara analisis kota kecil perlu dilakukan terpisah.

3.4 Normalisasi Min-Max

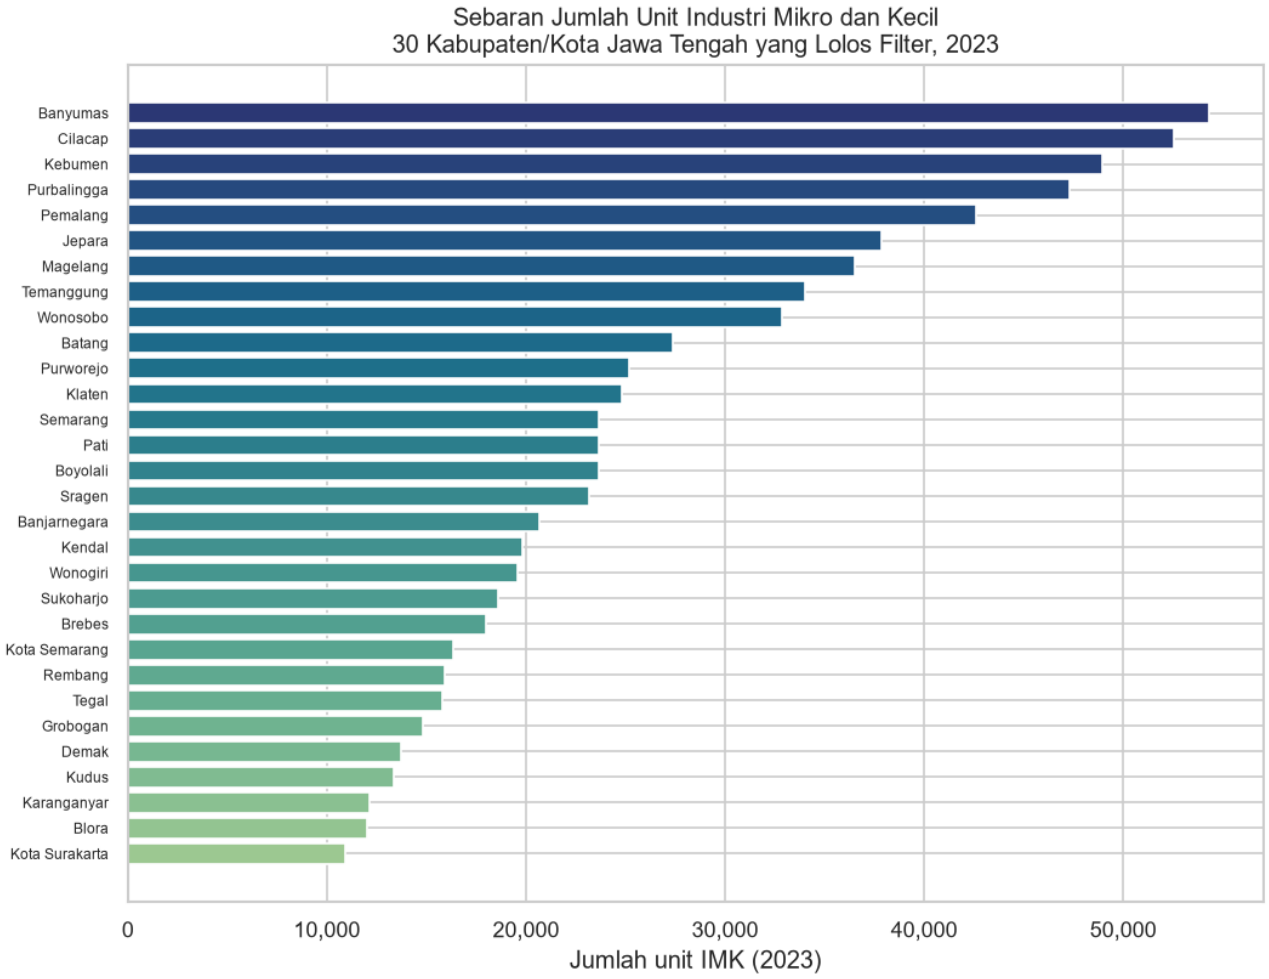
Normalisasi dilakukan pada 30 wilayah yang lolos dengan rumus x' = (x - min) / (max - min). Fitur yang dinormalisasi mewakili lima komponen ICP: penduduk, IMK per 100k, pedagang per 100k, IPM, pengeluaran per kapita, simpanan per kapita, tabungan per kapita, dan PDRB per kapita. Seluruh hasil berada pada rentang 0-1.

Catatan: Min-Max sensitif terhadap outlier. Setelah filter, simpanan per kapita masih sangat miring karena didominasi Kota Semarang. Pada milestone berikutnya perlu dipertimbangkan log-transform atau winsorization sebelum scoring.

4. Exploratory Data Analysis

EDA dilakukan pada 30 wilayah yang lolos. Fokusnya memetakan variasi antarwilayah dan mencari kombinasi indikator yang relevan untuk ICP Klay, bukan inferensi kausal.

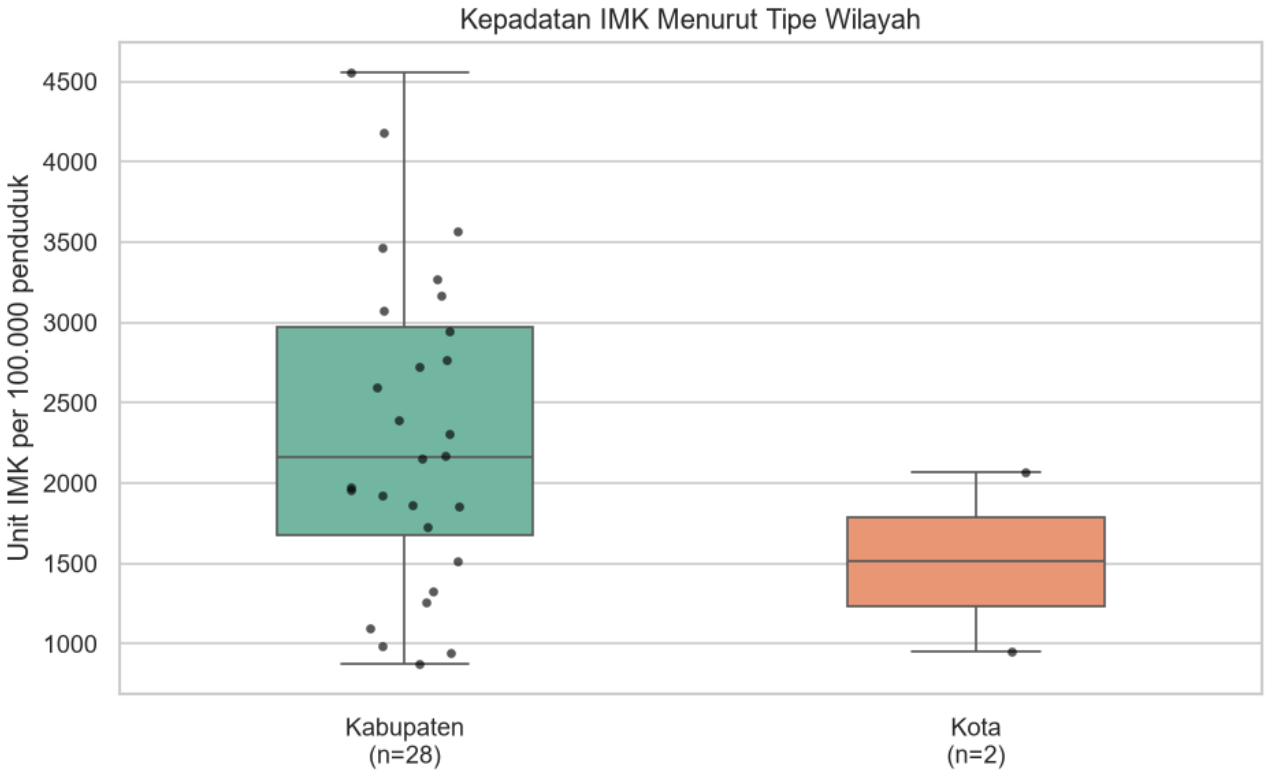
4.1 Sebaran jumlah unit IMK



Gambar 1. Sebaran jumlah unit IMK 2023 pada 30 wilayah yang lolos filter.

Distribusi jumlah IMK sangat timpang. Banyumas, Cilacap, Kebumen, Purbalingga, dan Pemalang masing-masing memiliki lebih dari 42 ribu unit, sedangkan wilayah lain jauh lebih kecil. Lima wilayah ini adalah pasar volume untuk paket dasar POS, tetapi belum tentu paling siap digital. Prioritas sebaiknya mempertimbangkan kepadatan relatif dan kesiapan digital, bukan hanya jumlah absolut.

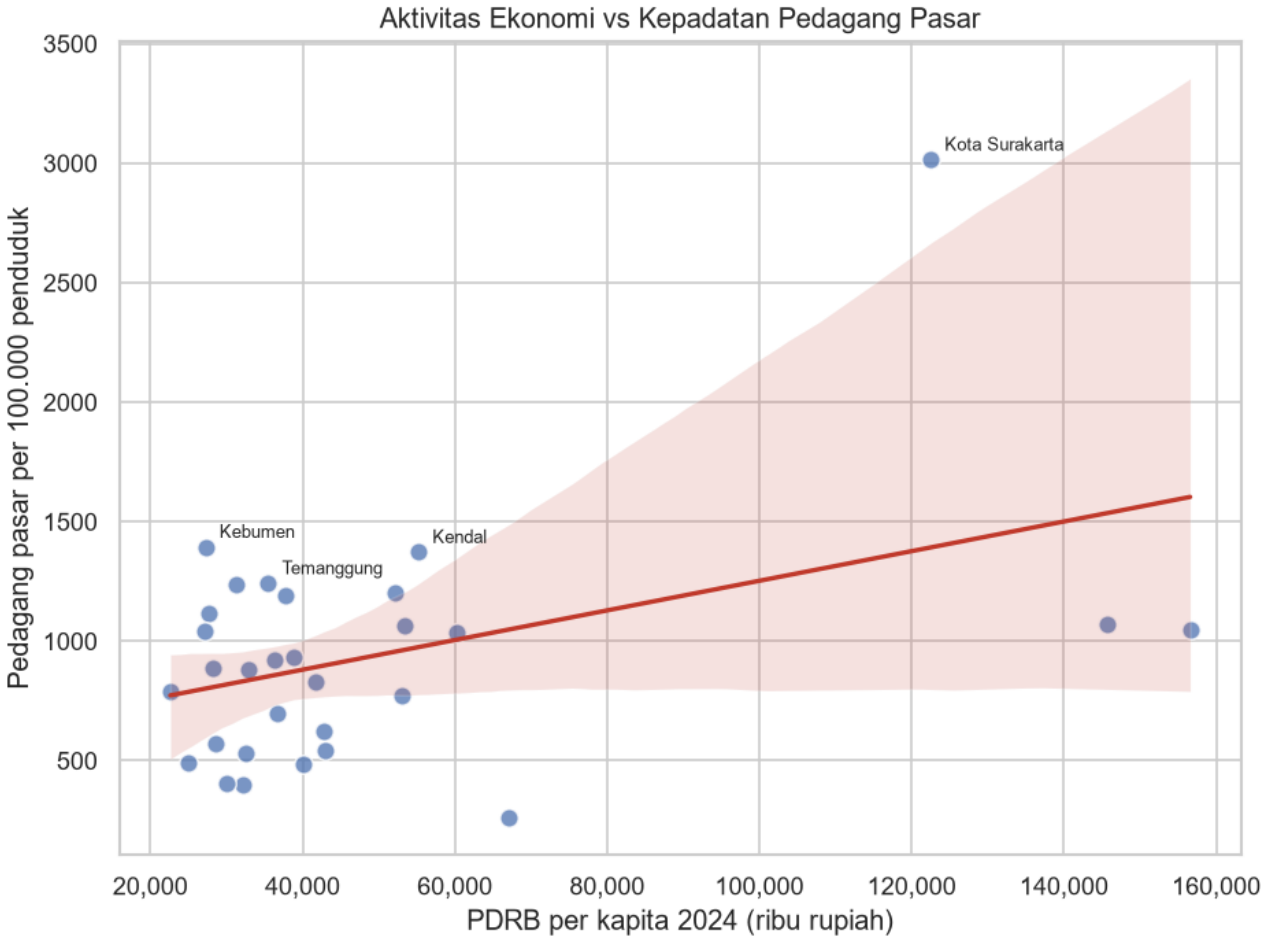
4.2 Kepadatan IMK menurut tipe wilayah



Gambar 2. Kepadatan IMK per 100.000 penduduk menurut tipe wilayah (n=28 kabupaten, n=2 kota).

Kabupaten memiliki rata-rata unit IMK jauh lebih besar (26.892 vs 13.612), tetapi kepadatan per 100 ribu penduduk juga lebih tinggi (2.307 vs 1.510). Kota yang lolos justru unggul pada kepadatan pedagang pasar, PDRB, dan IPM. Profil risiko dan pendekatan akuisisi berbeda: kabupaten cocok untuk penetrasi volume manufaktur/retail tradisional, kota cocok untuk merchant yang sudah siap digital dan bertransaksi lebih tinggi.

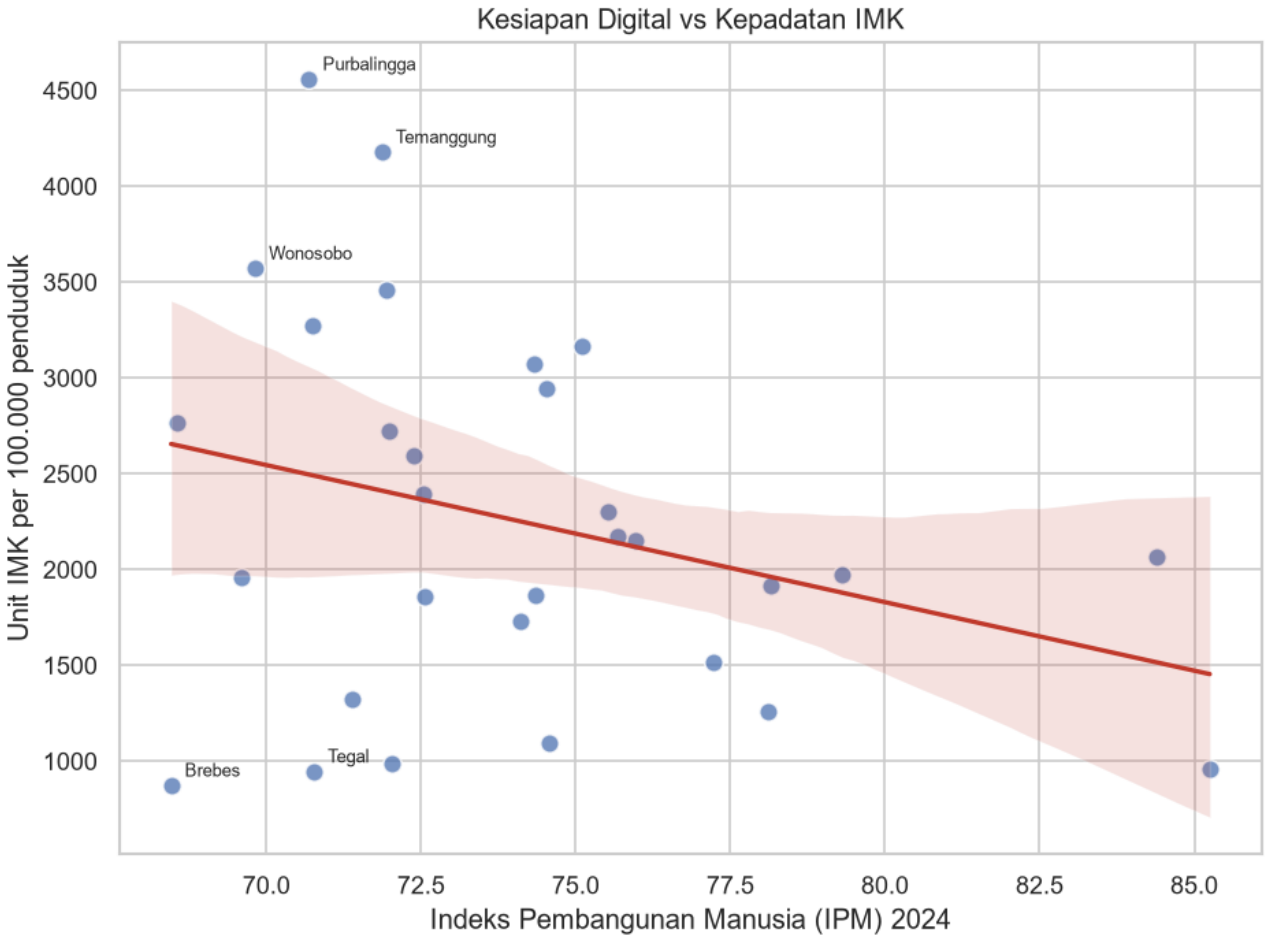
4.3 PDRB per kapita vs kepadatan pedagang pasar



Gambar 3. Hubungan PDRB per kapita 2024 dan pedagang pasar per 100.000 penduduk.

Korelasi positif sedang (r = 0,42). Wilayah dengan aktivitas ekonomi tinggi cenderung memiliki ekosistem pedagang pasar yang padat. Kota Surakarta adalah outlier positif: PDRB tinggi dan kepadatan pedagang sangat tinggi. Sebaliknya, beberapa kabupaten berpendapatan rendah tetap memiliki kepadatan pedagang tinggi (Kebumen, Temanggung, Purworejo), menandakan aktivitas retail tradisional besar tetapi daya beli belum tinggi. Wilayah seperti ini cocok untuk paket hemat dan edukasi digital.

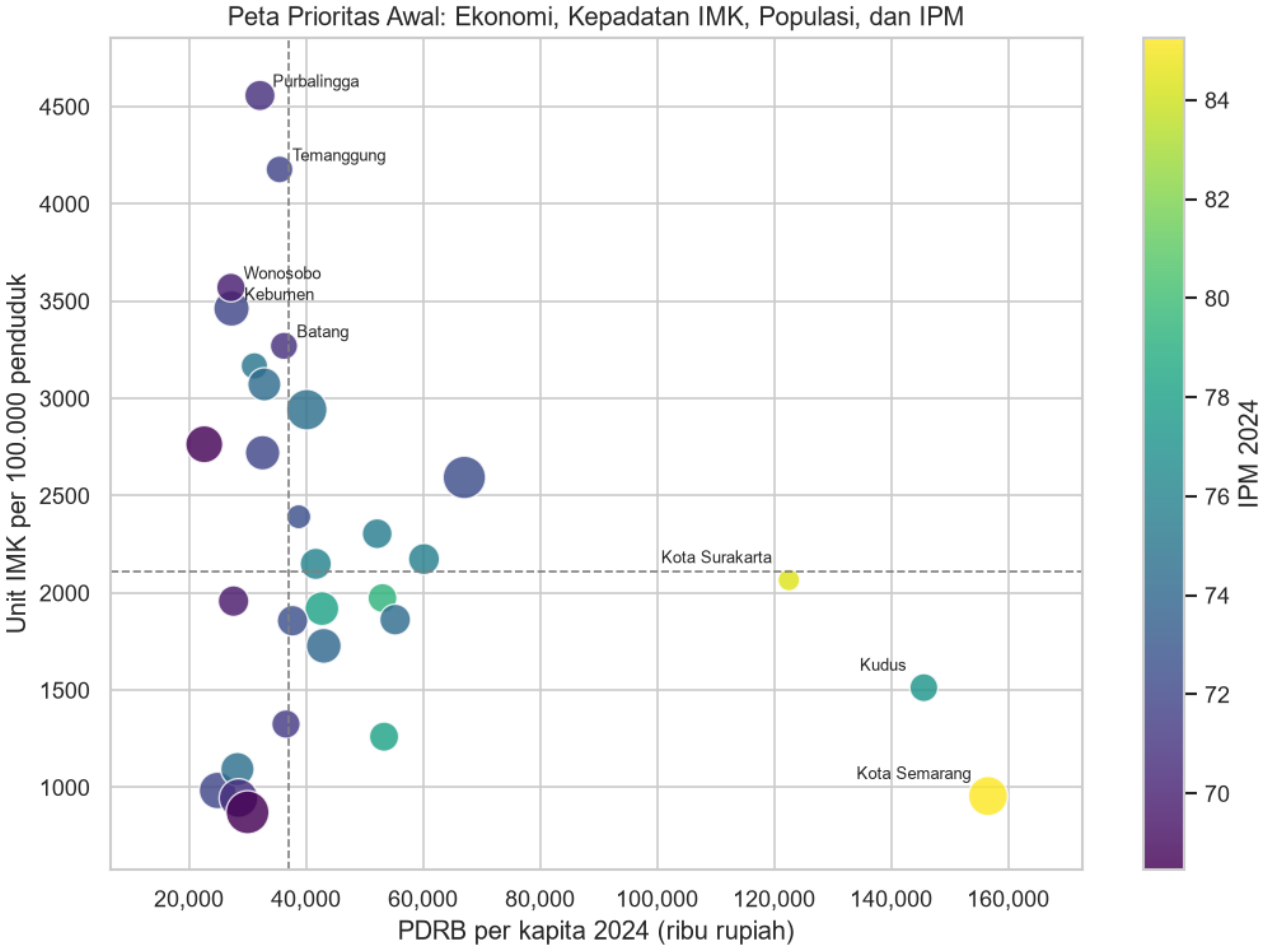
4.4 IPM vs kepadatan IMK



Gambar 4. Hubungan IPM 2024 dan kepadatan IMK per 100.000 penduduk.

Korelasinya negatif lemah (r = -0,30). Kabupaten dengan IMK padat (Purbalingga, Temanggung, Kebumen, Batang) justru memiliki IPM menengah, bukan tertinggi. Ini adalah gap yang menarik: basis usaha besar, tetapi kesiapan digital belum matang. Klay dapat memposisikan diri sebagai alat bantu adopsi digital, bukan sekadar POS. Sebaliknya, kota dengan IPM tinggi tetapi IMK rendah lebih cocok untuk produk analytics yang sudah advanced.

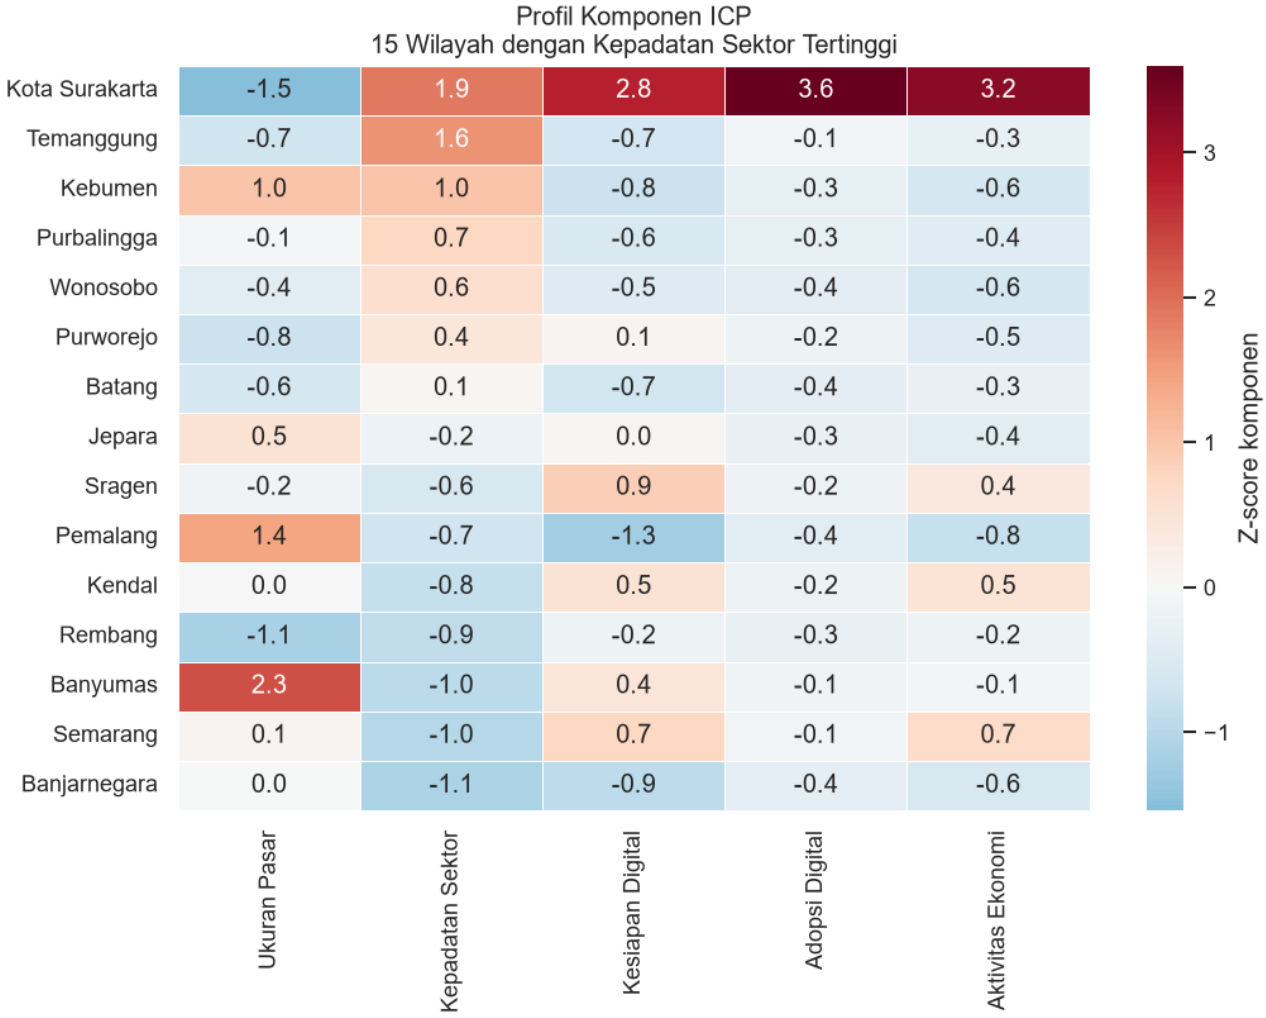
4.5 Peta prioritas awal (multivariat)



Gambar 5. PDRB vs kepadatan IMK; ukuran gelembung = populasi, warna = IPM 2024.

Empat kuadran memberi arah strategi. Kanan atas (PDRB tinggi, IMK padat) adalah wilayah siap scale untuk paket lengkap. Kiri atas (PDRB rendah, IMK padat) adalah volume besar dengan daya beli terbatas, cocok untuk paket hemat dan onboarding intensif. Kanan bawah (PDRB tinggi, IMK rendah) adalah ekonomi jasa/perdagangan, prospek merchant retail. Kiri bawah (keduanya rendah) menjadi prioritas rendah untuk sourcing awal. Kota Semarang dan Surakarta berada di kanan dengan IPM tinggi, sedangkan Kebumen, Wonosobo, dan Banjarnegara berada di kiri atas dengan populasi besar dan IPM menengah.

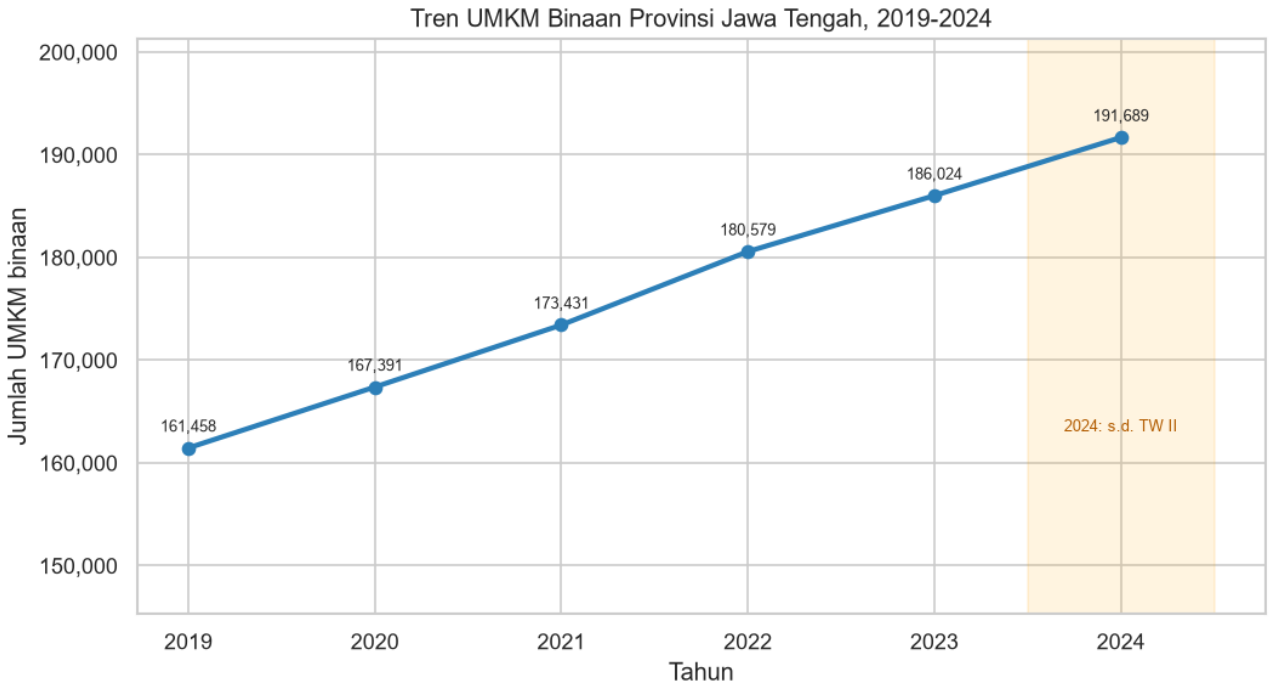
4.6 Profil komponen ICP



Gambar 6. Z-score lima komponen ICP pada 15 wilayah dengan kepadatan sektor tertinggi.

Wilayah dengan kepadatan sektor tinggi tidak seragam pada komponen lain. Sebagian unggul di ukuran pasar tetapi lemah di adopsi digital; sebagian lain seimbang. Untuk Klay, kombinasi kepadatan sektor tinggi dan kesiapan digital menengah adalah target paling efisien: kebutuhan nyata, tetapi belum terlalu matang sehingga masih ada ruang untuk value proposition POS/AI.

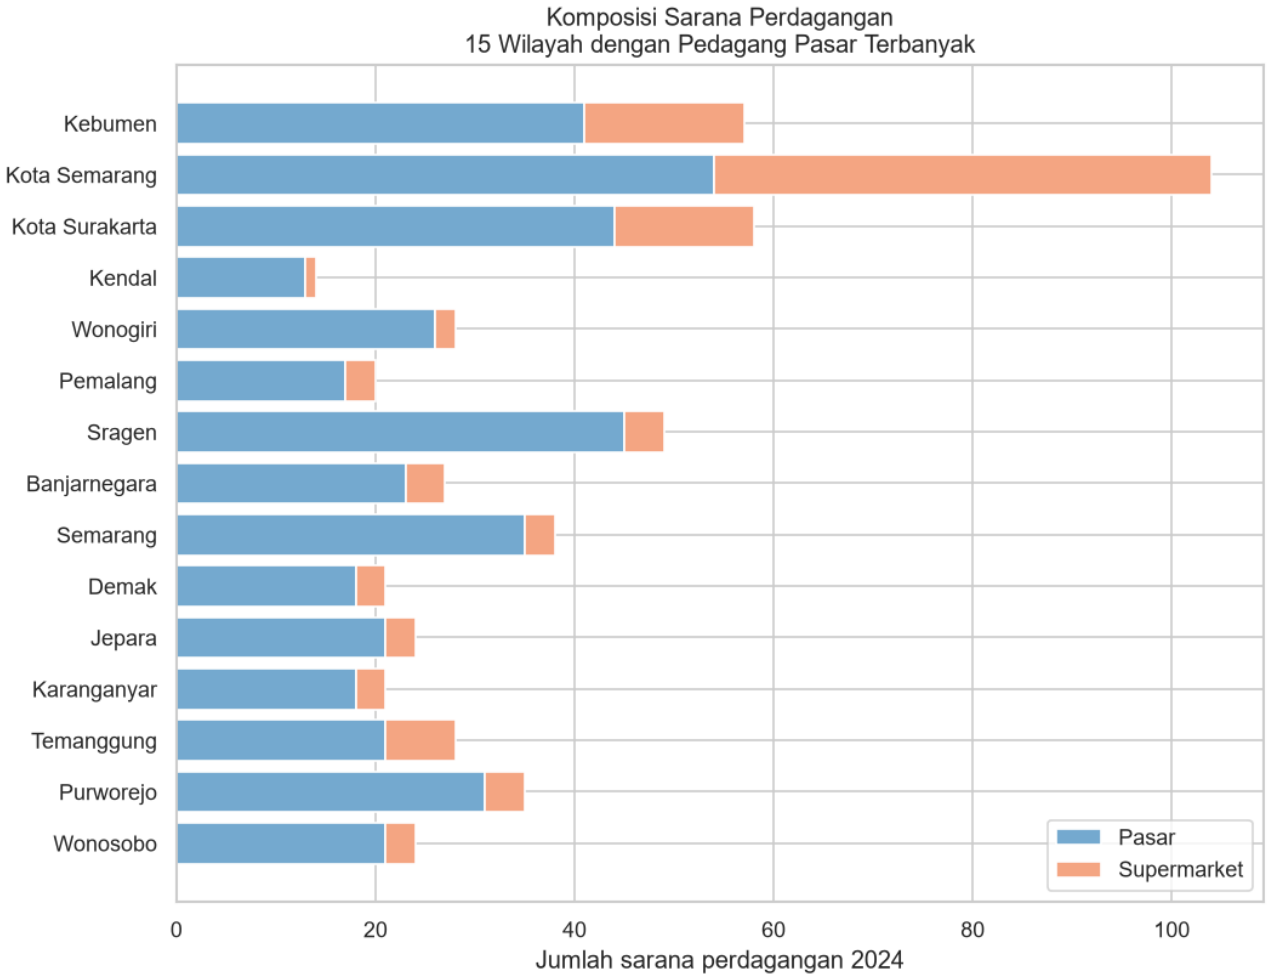
4.7 Tren UMKM binaan provinsi



Gambar 7. Jumlah UMKM binaan Provinsi Jawa Tengah, 2019-2024 (2024 s.d. TW II).

Populasi UMKM binaan tumbuh konsisten 3-4% per tahun (CAGR 2019-2023 = 3,6%). Angka 2024 baru mencakup TW II, jadi tidak sebanding dengan tahun penuh. Pertumbuhan yang stabil menandakan pasar sourcing yang terus bertambah, tetapi Klay perlu prioritas berbasis kualitas wilayah, bukan hanya mengejar volume.

4.8 Komposisi sarana perdagangan



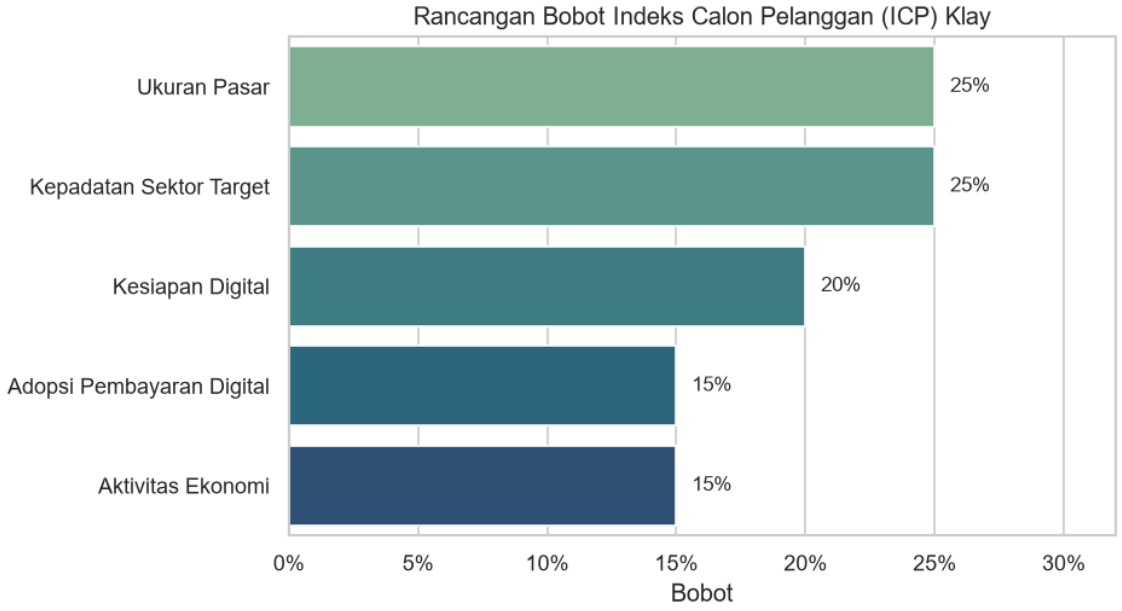
Gambar 8. Komposisi pasar dan supermarket pada 15 wilayah dengan pedagang pasar terbanyak.

Hampir seluruh ekosistem retail di wilayah terpilih berbasis pasar rakyat; supermarket hanya sebagian kecil. Ini memperkuat tesis bahwa pasar tradisional dan pedagangnya adalah segmen utama Klay, bukan hanya retail modern. Wilayah dengan pedagang pasar banyak tetapi supermarket sedikit (mis. Kebumen, Kendal) memiliki ketergantungan tinggi pada transaksi tunai, sehingga menjadi peluang untuk edukasi pembayaran digital dan pencatatan penjualan.

5. Rancangan Bobot Indeks Calon Pelanggan (ICP)

Bobot disusun dari lima komponen yang mencerminkan kesesuaian produk, kemampuan bayar, dan kemudahan akuisisi. Total bobot = 100%.

Komponen	Indikator	Arah	Bobot	Justifikasi
Ukuran Pasar	Jumlah penduduk; jumlah pedagang pasar	+	25%	Volume merchant dan transaksi menentukan potensi revenue; Klay memonetisasi per outlet.
Kepadatan Sektor Target	IMK/100k; pedagang pasar/100k	+	25%	F&B, retail, dan jasa adalah pengguna utama POS; kepadatan tinggi menurunkan biaya akuisisi.
Kesiapan Digital	IPM; pengeluaran per kapita	+	20%	Literasi dan daya beli menurunkan biaya onboarding serta churn.
Adopsi Pembayaran Digital	Simpanan per kapita; tabungan per kapita	+	15%	Proxy kebiasaan nontunai dan akses keuangan; QRIS ideal tetapi belum tersedia per kab/kota.
Aktivitas Ekonomi	PDRB per kapita	+	15%	Intensitas bisnis dan kemampuan bayar menentukan kesediaan berlangganan.



Gambar 9. Rancangan bobot ICP Klay; total 100%.

5.1 Formula skor (rancangan, belum dihitung)

ICP(i) = 0,25 U(i) + 0,25 K(i) + 0,20 D(i) + 0,15 A(i) + 0,15 E(i), dengan U = Ukuran Pasar, K = Kepadatan Sektor Target, D = Kesiapan Digital, A = Adopsi Pembayaran Digital, dan E = Aktivitas Ekonomi. Semua komponen berada pada 0-1, sehingga ICP juga 0-1. Skor akhir, peringkat, Top 5, dan uji sensitivitas bobot tidak dihitung di Tugas 2.

5.2 Rasional pembobotan

- Ukuran Pasar (25%) dan Kepadatan Sektor Target (25%) mendapat bobot terbesar karena keduanya paling langsung menentukan jumlah leads dan potensi revenue.
- Kesiapan Digital (20%) lebih tinggi dari adopsi/aktivitas karena Klay adalah produk software: wilayah dengan literasi dan daya beli lebih baik lebih murah di-onboard dan lebih kecil churn.
- Adopsi Pembayaran Digital (15%) penting, tetapi datanya hanya proxy simpanan/tabungan, bukan QRIS merchant. Bobotnya dibatasi agar tidak mendominasi.
- Aktivitas Ekonomi (15%) memberi sinyal daya beli, tetapi PDRB per kapita tidak secara langsung mengukur kesiapan adopsi software.

6. Kesimpulan dan Keterbatasan

6.1 Kesimpulan

- Data 35 kabupaten/kota berhasil digabung dari empat sumber publik dengan kunci wilayah yang konsisten; tidak ada missing atau duplikat pada data mentah.
- Setelah filter transparan, 30 wilayah siap dianalisis. Lima wilayah gugur: Kabupaten Pekalongan (outlier kepadatan IMK) serta Kota Magelang, Kota Salatiga, Kota Pekalongan, dan Kota Tegal (basis IMK < 10.000 unit).
- EDA menunjukkan dua klaster besar: kabupaten berbasis manufaktur/retail tradisional dengan volume besar tetapi IPM/PDRB menengah, dan kota berbasis jasa/perdagangan dengan IPM/PDRB tinggi tetapi basis IMK lebih kecil.
- Rancangan bobot ICP memberi prioritas seimbang pada ukuran pasar dan kepadatan sektor (50% gabungan), dengan kesiapan digital sebagai faktor kualitas (20%), serta adopsi pembayaran dan aktivitas ekonomi sebagai pelengkap (30%).
- Wilayah dengan kepadatan sektor tinggi dan kesiapan digital menengah (mis. Kebumen, Purbalingga, Temanggung, Batang) adalah kandidat menarik untuk ekspansi berbasis volume dan edukasi digital; kota besar (Semarang, Surakarta) lebih cocok untuk paket advanced.

6.2 Keterbatasan

- Proxy sektor: IMK hanya mencakup industri manufaktur mikro/kecil, bukan seluruh UMKM. Pedagang pasar hanya mencakup pedagang di pasar rakyat, bukan seluruh retail.
- Data adopsi digital: QRIS merchant per kabupaten/kota tidak tersedia publik; simpanan/tabungan per kapita hanya proxy tidak langsung.
- Level agregasi: UMKM binaan hanya tersedia di level provinsi dan hanya mencakup UMKM yang difasilitasi Dinkop, bukan total UMKM.
- Filter: ambang 10.000 unit IMK mengeluarkan empat dari enam kota, sehingga hasil lebih representatif untuk kabupaten. Analisis kota kecil perlu dilakukan terpisah.
- Desain cross-sectional: data 2023-2024 tidak memungkinkan inferensi kausal atau tren jangka panjang per wilayah.
- Normalisasi: Min-Max sensitif terhadap outlier. Simpanan per kapita masih sangat miring (didominasi Kota Semarang), sehingga perlu log-transform atau winsorization pada milestone berikutnya.

6.3 Rencana milestone berikutnya

- Finalisasi fitur dan uji sensitivitas bobot ICP.
- Segmentasi wilayah dengan K-Means (jumlah klaster diuji dengan elbow/silhouette).
- Perhitungan skor akhir dan penentuan Top 5 wilayah.
- Validasi eksternal (mis. data QRIS atau survei lapangan) bila tersedia.

Lampiran

A. Struktur deliverable

Path	Isi
Tugas2_DS_Kelompok13.ipynb	Notebook utama, tereksekusi tanpa error
data/raw/	PDF BPS, XLSX penduduk/IPM/UMKM
data/processed/master_raw.csv	Dataset gabungan 35 wilayah sebelum filter
data/processed/master_clean.csv	Dataset 30 wilayah setelah filter + normalisasi
data/processed/wilayah_tereliminasi.csv	Daftar 5 wilayah gugur dan alasannya
data/processed/provinsi_umkm_series.csv	Time series UMKM binaan 2019-2024
figures/	Sembilan figur EDA dan bobot ICP
scripts/build_dataset.py	Skrip ekstraksi dan pembentukan dataset
scripts/make_notebook.py	Generator notebook
scripts/make_report.py	Generator laporan PDF

B. Cara menjalankan ulang

1. Install dependensi: pandas, numpy, matplotlib, seaborn, scikit-learn, pdfplumber, nbformat, nbconvert, fpdf2.

2. Letakkan raw data di data/raw (lihat README).

3. Jalankan python scripts/build_dataset.py untuk membentuk ulang dataset.

4. Jalankan jupyter nbconvert --to notebook --execute --inplace Tugas2_DS_Kelompok13.ipynb.

5. Jalankan python scripts/make_report.py untuk menghasilkan laporan PDF.

Catatan: lengkapi nama anggota sebelum submit. ZIP akhir: Tugas2_DS_Kelompok13.zip